

ΑΡΙΣΤΟΤΕΛΕΙΟ
ΠΑΝΕΠΙΣΤΗΜΙΟ
ΘΕΣΣΑΛΟΝΙΚΗΣ

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Τομέας Ηλεκτρονικής και Υπολογιστών

Εργαστήριο Επεξεργασίας Πληροφοριών και Υπολογισμών

Διπλωματική Εργασία

“Talking Heads”: Πρόβλεψη Φωνημάτων από Βίντεο

Όνομα	Βαπόρης Δημήτριος
A.E.M.	10625
Email	dvaporis@ece.auth.gr
Επιβλέπων Καθηγητής	Ντελόπουλος Αναστάσιος

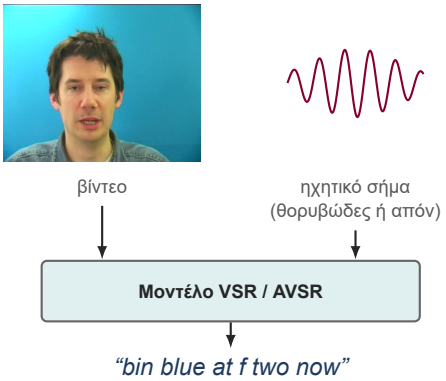
Εαρινό Εξάμηνο 2026

Περιεχόμενα

- Εισαγωγή
- Τεχνικό Υπόβαθρο
- Μεθοδολογία
- Εκπαίδευση
- Αξιολόγηση της Μεθοδολογίας
- Συμπεράσματα και Μελλοντικές Επεκτάσεις

Ορισμός του Προβλήματος

- Lip reading: αναγνώριση ομιλίας από βίντεο
- VSR: αποκλειστικά οπτικά στοιχεία
- AVSR: οπτικά και ακουστικά στοιχεία
- Δυσκολία: «bin» και «pin» φαίνονται ίδια
- Με θόρυβο: κρίση αξιοπιστίας κάθε τροπικότητας
- Εφαρμογές: βαρήκοοι, Augmented Reality, θορυβώδεις χώροι



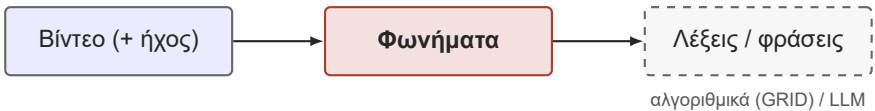
Διαθέσιμες Μέθοδοι & Η Συγκεκριμένη Εργασία

Διαθέσιμες Μέθοδοι

- LipNet, WLAS: 3D CNN + RNN/attention
- AV-HuBERT, Auto-AVSR: προεκπαίδευση μεγάλης κλίμακας
- VALLR: φωνήματα, έπειτα λέξεις μέσω κατάλληλα fine-tuned LLM

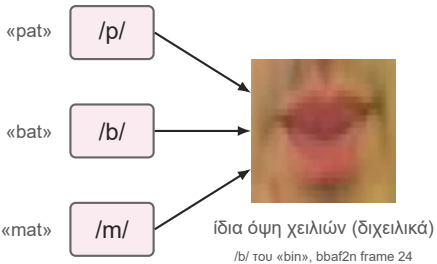
Η Συγκεκριμένη Εργασία

- Εστίαση: πρόβλεψη φωνημάτων ανά frame
- Visual μοντέλο: βουβό βίντεο χειλιών
- Audiovisual μοντέλο: παραμορφωμένο βίντεο και θορυβώδης ήχος
- 3 πειράματα στο GRID dataset

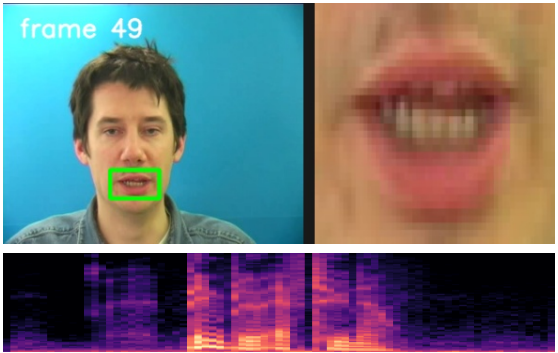


Φωνήματα και Visemes

- Φώνημα: η ελάχιστη μονάδα φωνής
- Π.χ. /b/ στην αρχή της λέξης «bat»
- Viseme: φωνήματα με ίδια όψη χειλιών
- Visemes: πληροφορία τόπου, όχι τρόπου εκφοράς
- Ο ήχος διαχωρίζει φωνήματα ίδιου viseme
- Ομαδοποίηση: τόπος και τρόπος εκφοράς, έμφωνο/άφωνο



Προεπεξεργασία Δεδομένων



bbaf2n.mpg: εξαγωγή χειλιών (frame 49) και log Mel-Spectrogram

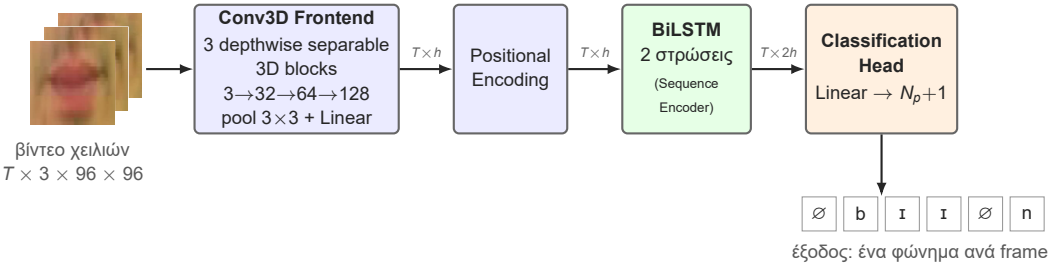
Βίντεο

- MediaPipe Face Landmarker: τοπόσημα χειλιών
- Bounding box με padding 30%
- Resize σε 224×224, τελικά 96×96
- Περιοχή περίπου 1.6% του αρχικού frame

Ήχος

- Log Mel-Spectrogram, 80 φίλτρα mel
- Βήμα $N_h = f_s/f_v$: ευθυγράμμιση με frames του βίντεο

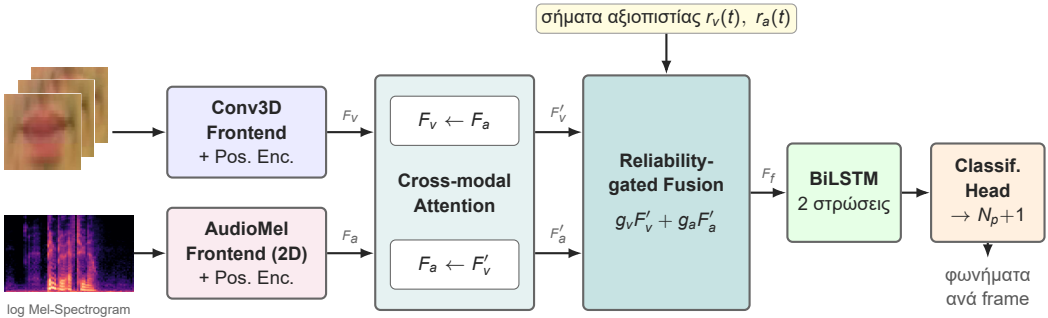
Visual Μοντέλο



- 3D συνέλιξη: εμφάνιση και κίνηση χειλιών
- Depthwise separable: έως 22× λιγότερες παράμετροι
- Χρονικό stride 1: διατήρηση όλων των frames

- Frontend: receptive field 7 frames
- BiLSTM: παρακείμενο (context) παρελθόντος και μέλλοντος
- Έξοδος: φωνήματα + blank ανά frame

Audiovisual Μοντέλο



- Δύο ανεξάρτητα, συμμετρικά συνελικτικά frontends
- Ήχος: 2D depthwise separable συνέλιξη
- Κοινός χρονικός άξονας, χωρίς resampling

- Cross-modal Attention: ανταλλαγή πληροφορίας τροπικοτήτων
- Fusion: σταθμισμένο άθροισμα των features με βάση την αξιοπιστία

Cross-modal Attention & Reliability-gated Fusion

Cross-modal Attention

- Και στις δύο κατευθύνσεις
- Κάθε frame αντλεί από χρήσιμα frames
- Residual: προστασία της αναπαράστασης κάθε τροπικότητας

Reliability-gated Fusion

- MLP + softmax: gates $g_v + g_a = 1$
- $|F'_v - F'_a|$: ένδειξη ασυμφωνίας τροπικοτήτων
- r_v, r_a: γνωστά (proof of concept)

Cross-modal Attention

$$F'_v = \mathrm{LN}\big(F_v + \mathrm{MHA}(Q{=}F_v,\ K{=}V{=}F_a)\big)$$
$$F'_a = \mathrm{LN}\big(F_a + \mathrm{MHA}(Q{=}F_a,\ K{=}V{=}F'_v)\big)$$

Reliability-gated Fusion

$$u(t) = \big[F'_v \,\|\, F'_a \,\|\, |F'_v - F'_a| \,\|\, r_v \,\|\, r_a\big]$$
$$(g_v, g_a) = \mathrm{softmax}\,\big(\mathrm{MLP}(u(t))\big)$$
$$F_f(t) = g_v(t)\, F'_v(t) + g_a(t)\, F'_a(t)$$

Ετικέτες & Συνάρτηση Κόστους

Δεδομένα Εκπαίδευσης

- Ετικέτες ανά frame: eSpeak-NG + wav2vec2
- Soft targets: 85% στο σωστό φώνημα
- 15% σε όμοια φωνήματα (viseme, άρθρωση)
- Augmentation: flip, color jitter, cutout

VisemeAwareFrameLoss

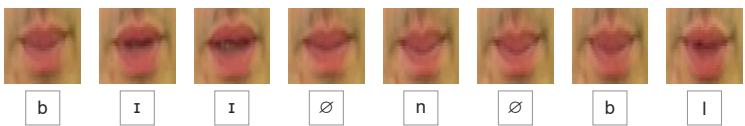
$$\mathcal{L} = \mathcal{L}_f + \lambda_c \mathcal{L}_c, \qquad \lambda_c = 0.3$$

- $\mathcal{L}_f$: cross-entropy ανά frame → χρονισμός
- $\mathcal{L}_c$: CTC → ορθή αλληλουχία
- Audiovisual: + auxiliary CTC ανά τροπικότητα

$$\mathcal{L}_{AV} = \mathcal{L} + \lambda_a(\mathcal{L}_v + \mathcal{L}_a), \qquad \lambda_a = 0.1$$

ετικέτες ανά frame

bbaf2n, frames 24–31: «bin bl(ue)»



Θόρυβος & Σήματα Αξιοπιστίας (Audiovisual)

Βίντεο

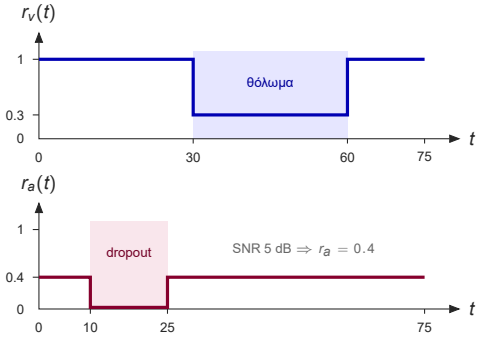
- Ένα συνεχές span παραμόρφωσης περίπου 30 frames
- Μηδενισμός / πάγωμα: $r_v = 0$, θόλωμα: $r_v = 0.3$

Ήχος

- Συνεχής λευκός θόρυβος ή «βαβούρα», $\rho \in [-5, 15]$ dB
- r_a: γραμμικά από το SNR ρ
- Προαιρετικό dropout 15 frames με $p = 0.3$: $r_a = 0$

Εκπαίδευση

- Θόρυβος πάντα και στις δύο τροπικότητες
- Modality dropout ($p = 0.15$) για ευρωστία



ενδεικτικό παράδειγμα (75 frames)

$$r_a = \mathrm{clip}\left(\tfrac{\rho+5}{25},\ 0,\ 1\right)$$

Dataset & Κριτήρια Αξιολόγησης

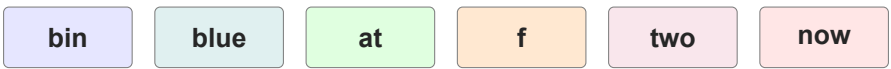
GRID Audio-Visual Speech Corpus

- 34 ομιλητές $\times$ 1000 φράσεις
- Ομιλητής s1: 700 / 150 / 150 clips
- 75 frames ανά clip (25 fps)
- Περιορισμένο λεξιλόγιο και σύνταξη

Κριτήρια

- TER: απόσταση Levenshtein / μήκος αναφοράς
- Frame Accuracy: ποσοστό ορθών προβλέψεων φωνημάτων ανά frame
- ΔTER: 95% CI με paired bootstrap

bbaf2n.mpg

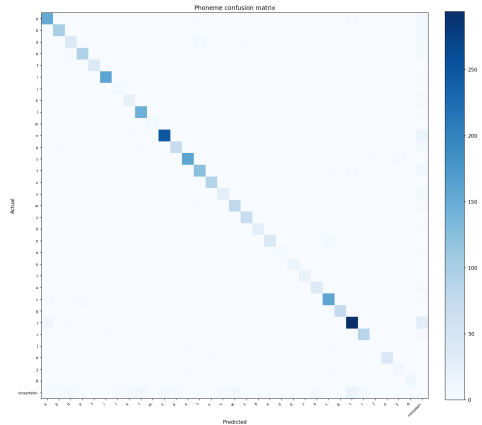


Πείραμα 1α: Μελέτη Αφαίρεσης (Visual Μοντέλο)

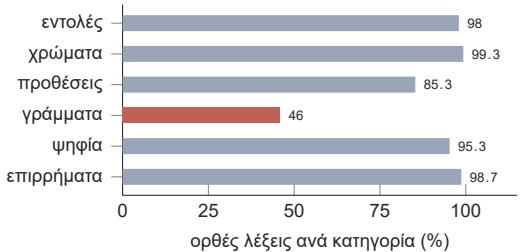
Εκδοχή	Sequence Encoder	Loss	Targets CE	Test TER	Test Frame Acc.
V1	BiLSTM	CE + CTC	soft	**0.1219**	**0.8474**
V2	Transformer	CE + CTC	soft	0.1566	0.8394
V3	— (projection head)	CE + CTC	soft	0.2464	0.8122
V4	BiLSTM	CTC	—	0.1869	0.4743
V5	BiLSTM	CE	soft	0.1419	0.8401
V6	BiLSTM	CE + CTC	hard	0.1289	0.8456

- Χωρίς sequence encoder: TER υπερδιπλασιάζεται
- BiLSTM $>$ Transformer στο μικρό dataset
- CE + CTC $>$ κάθε όρος ξεχωριστά
- Soft targets: μικρή αλλά θετική επίδραση

Πείραμα 1β: Πρόβλεψη Φωνημάτων & Λέξεων



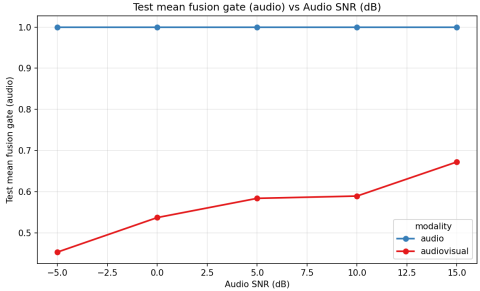
- Test TER: 0.1241
- Σφάλματα κυρίως εισαγωγές / παραλείψεις φωνημάτων
- Λέξεις: δυναμικός προγραμματισμός, viseme-aware edit distance
- Ορθές λέξεις 87.1%, ορθές προτάσεις 38%



Πείραμα 2α: Αύξηση του SNR του Ήχου

Βίντεο: περίπου 30 παραμορφωμένα frames | Ήχος: SNR από -5 έως 15 dB



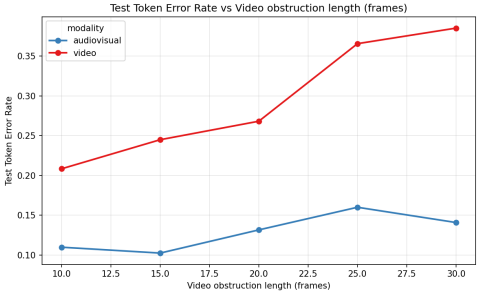


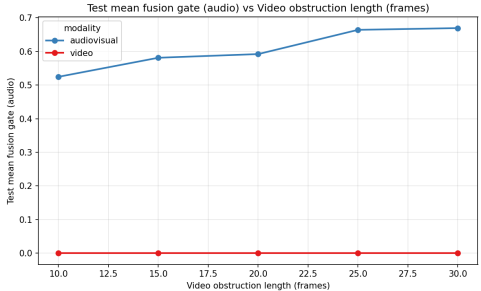
- Audiovisual υπερέχει σε κάθε τιμή SNR
- Μικρότερη επίδραση του SNR στο audiovisual

- Η audio gate αυξάνεται με το SNR
- -5 dB: $g_a < 0.5$, 15 dB: $g_a \approx 0.7$

Πείραμα 2β: Αύξηση των Παραμορφωμένων Frames

Ήχος: 15 dB SNR (+ dropout) | Βίντεο: 10 έως 30 παραμορφωμένα frames





- Video μοντέλο: TER σχεδόν διπλασιάζεται
- Audiovisual: μικρή επιδείνωση, πάντα καλύτερο

- Η audio gate αυξάνεται με τα frames
- Το βίντεο παραμένει χρήσιμο, ακόμα και παραμορφωμένο

Πείραμα 3: Σύγκριση με State of the Art

Ήχος: 0 dB SNR, dropout 0.6 s με $p = 0.3$ | Βίντεο: 25 παραμορφωμένα frames

Μοντέλο	Είσοδος	Παράμετροι	Test TER ↓	ΔTER έναντι AV [95% CI]
Audiovisual (προτεινόμενο)	ήχος + βίντεο	**3.6M**	**0.171**	—
Allosaurus	ήχος	10.8M	0.186	+0.014 [−0.013, +0.043]
icefall TDNN-LSTM-CTC	ήχος	10.9M	0.251	+0.079 [+0.054, +0.105]
LipNet	βίντεο	6.6M	0.335	+0.164 [+0.135, +0.194]
Auto-AVSR	βίντεο	182.1M (28.4M)	0.363	+0.192 [+0.165, +0.220]

- Audiovisual: καλύτερο TER, λιγότερες παράμετροι
- Allosaurus: παρόμοια επίδοση (CI περιέχει 0)
- Μοντέλα ήχου υπερέχουν μοντέλων βίντεο
- Πλεονέκτημα AV: γνωστά σήματα αξιοπιστίας

Συμπεράσματα

- Μόνο από βίντεο: όχι πλήρης λύση (visemes)
- Το παρακείμενο (context) μειώνει την επίδραση των visemes
- Βέλτιστο visual: 3D CNN + BiLSTM, CE + CTC
- Ο ήχος βοηθά, ακόμα και θορυβώδης
- Το fusion προσαρμόζεται στην αξιοπιστία κάθε τροπικότητας
- Audiovisual: ίδιες ή καλύτερες επιδόσεις από SoA μίας τροπικότητας, λιγότερες παράμετροι

Μελλοντικές Επεκτάσεις

- In the wild datasets (LRS2, LRS3)
- Πρόβλεψη φράσεων μέσω fine-tuned LLM
- Αναγνώριση ομιλίας σε πραγματικό χρόνο
- Υποστήριξη πολλαπλών γλωσσών
- Εκτίμηση αξιοπιστίας από το ίδιο μοντέλο
- Πλήρης έναντι depthwise separable συνέλιξης
- Μελέτη αφαίρεσης της εισόδου του fusion

Ευχαριστώ για την προσοχή σας!

Ερωτήσεις;